

An Alien Mind

一种异于人类的智能

OPENAI / 安全 · 研究

Jakub Pachocki

OpenAI 首席科学家

2026 年 9 月 6 日

音频时长 17:31

中文全译 · 中小學生閱讀注釋 · 重點高亮

保留原稿 13 頁結構與封面圖。正文呈現作者原意；綠色注釋框為譯者補充，淺黃色標出重點語句。

目录

完整翻译原稿文章，保留章节顺序、原有强调段落、列表、脚注及来源链接。阅读小注面向中小學生，帮助理解概念；作者的预测与判断保留原有语气。

我们尚未完全理解的智能	4
教会机器关爱人类	6
监测 AI 如何举一反三	8
让防御能力跟上 AI 的发展	10
把握递归自我改进的节奏	11
接下来怎么办？	12

发布时间 2026 年 9 月 6 日
归档主题 对齐 · 2026
音频时长 17:31
原文来源 openai.com/index/an-alien-mind/

怎么读：先看浅黄色重点句，再读正文；遇到术语，可看页末的“阅读小注”。原文脚注 [1]、[2] 见第 13 页。绿色正文词句保留原稿可点击链接。

文章

一种异于人类的智能

作者：Jakub Pachocki • OpenAI 首席科学家

2023 年年中，在名为“RLSlow”的研究项目中，我们首次取得了一些结果，使我们有信心扩大推理模型的训练规模，释放预训练模型自行形成思维链的能力。那天晚上，西蒙（Szymon）和我一直待在办公室。我们想的不是这项技术将带来多么惊人的基准测试成绩、产品或科研成果，而是在努力消化一个让人警醒的事实：在我们有生之年，真的会看到明显比我们更聪明的机器；而且，这些系统的轮廓已经显现。我们也在想，该怎样让人们意识到这件事的重要性。

三年后，推理语言模型正在经济活动中迅速发展，并开始拓展科学的边界。它们能够操作计算机和图形界面，与人类及其他 AI 协作，并开展研究项目。它们也在改变计算机安全的局面，同时带来明显的新危险。

这段时间涌现了许多新研究，我们对这些系统的理解也与 2023 年有所不同。根据内部研究结果，我强烈预期，这样的进步速度有可能持续下去，进入递归自我改进阶段。如果 AI 沿着当前路径继续发展，那么未来几年出现的系统，很可能会实现幅度相当、甚至更大的能力跃升，并越来越多地推动自身的发展。

这是一个需要极其谨慎的时刻。我担心，没有人做好准备，应对机器智能持续快速提升所带来的后果。OpenAI 将继续寻找对齐与监测的技术方案，构建防御系统，并在必要时自主暂停进一步扩大规模；但我认为，还需要更广泛的干预。

阅读小注 • 译者补充

推理模型：能通过分步骤推理处理问题的 AI。“思维链”指用文字展开的推理过程，不等于人类大脑的真实思想。

标题中的 alien 指“与人类不同、陌生”，不是说外星生命。文中的“可能”“我预期”表达作者的判断。

第 01 节

我们尚未完全理解的智能

从总体上看，机器智能的进步由不断增强的计算能力推动。大约在 2017 年，我们在多个研究项目中看到，扩大规模持续带来收益[1]，于是 OpenAI 深刻认识到了这一点。因此，我们寻求的算力远超最初计划，并逐渐把研究集中到少数能大幅扩展规模的方向上。我们相信，只有这样才能站在 AI 研究前沿，并影响通用人工智能（AGI）给世界带来的变化。

一路上，团队和研究者个人开发了新算法，展现了新的巧思。我主要将这些看作扩大规模过程中出现的发现。深度学习这门科学仍处于早期，有意义的算法进步往往与能否获得算力相关。如果把眼光放到数年尺度，AI 正随着所用计算系统规模的扩大而不断变得更聪明。

正如雷·库兹韦尔在 20 世纪末所作的预测，我们如今正处在计算机发展史上的这样一个时刻：机器智能开始以能带来重大变革的方式超越人类智能。

AI 与其说是被“设计”出来的，不如说是被“训练生长”出来的。粗略地说，它是在难以想象的大量算力上，反复执行一个相对简单的优化步骤的产物。由此形成的系统极其复杂，能处理抽象概念，也能模拟人类行为的某些方面。我们可以像研究神经科学那样，发现系统内部涌现的一些小机制；但也像神经科学一样，我们仍无法用自己完全理解的方式，描述它整体上如何运作。

对基于深度学习的 AI 的研究，在很大程度上是一门实验科学。我们投入大量精力，构建有理论依据的算法，并作出可检验的预测。但从根本上说，大规模训练就是实验，其结果有时会出乎意料。而且，系统越强大，结果就越难解释。

当前算法通常会更快地提升容易测量的能力，而那些难以客观量化的能力提升得较慢。这让问题更加复杂。

阅读小注 • 译者补充

算力：计算机完成计算工作的能力。算法：解决问题的步骤和规则。深度学习：通过大量例子调整多层神经网络的方法。

“训练生长”是一种比喻，不表示 AI 是生命。AGI 指能广泛处理不同任务的通用人工智能；这里没有断言它已经实现。

我们花了大量时间，研究这些能力如何泛化，以及应优先推进哪些在未来几年最重要的技能。比如，我们认为，如果专门投入更多精力，可以让模型更擅长数学研究。但我们并未把这个方向放在首位，因为我们感到，递归自我改进（RSI）和自动化对齐研究更加紧迫。后面我会进一步讨论。

通过扩大深度学习规模获得的智能，不能直接与人类智能作比较。AI 要在现实世界中产生重大影响——变得非常有用或非常危险——并不需要在所有能力上达到或超过人类；只需要在足够多的方面超过人类。随着它在越来越多的方面超越人类，我们也越来越难准确理解它究竟有多强。

阅读小注 • 译者补充

泛化：把学到的本领用到没见过的新情境。就像学会一道应用题的方法后，还能解决换了背景的新题。

RSI（递归自我改进）：AI 帮助改进 AI，改进后的 AI 又继续推动下一轮改进。能否持续、速度多快，仍需研究验证。

阅读提醒：擅长很多任务，并不等于具有人类全部能力；也不能仅凭一次考试或一个排行榜判断 AI 的整体能力。

第 02 节

教会机器关爱人类

机器智能与人类智能的形成过程有根本差异，因此，我们不能默认它会遵循人类的原则，也不能假定它会像人类一样，把这些原则运用到新情境。AI 研究的核心问题是“对齐”：让 AI 按照人类的标准，努力做正确的事。

为了梳理实际研究方向，我认为可以把对齐区分为“目标对齐”和“价值对齐”。

目标对齐大致是在问：“AI 是否努力完成交给它的目标？”它包括遵守指令的优先级，以及与人交流、协作并尝试理解人的目标等能力。这类研究方向一直具有很强的实际应用价值。

价值对齐是模型更内在的一种特性：它能坚持一组高层次原则，并把这些原则运用到新情境中。即使目标模糊或相互冲突，或者身处陌生、有意对抗它的环境，也能合理行事。对齐的 AI 应当诚实、正直，并关爱人类。

当然，价值对齐和目标对齐的边界可能并不清晰。真正重视目标，也需要尝试推断目标背后的意图和价值观。不过，当我谈论对齐研究的长期重要性时，通常指的是价值对齐。

AI 对齐的根本挑战是泛化。机器越聪明，就越会处理更高层次的概念，所处环境与训练时接触到的环境也越来越不同。它们可能无法把训练过程中被教导和强化的价值原则，正确运用到新情境；我们也很难确定它们会怎样行动。AI 所处的整个应用生态又在快速变化，这让问题更难。例如，今天训练的 AI，需要能可靠地应对与各种其他 AI 的互动。至关重要，无论未来的 AI 是否认为自己正在接受人类监督，它都需要继续遵循人类价值观。

目前，实际用于对齐训练的方法主要有两大类。

阅读小注 • 译者补充

目标对齐与价值对齐：例如“帮我提高成绩”，既要帮助学习，也要遵守诚实原则，不能通过作弊达成目标。

“关爱”在这里描述期望 AI 遵循的行为原则，不代表已经证明机器会像人一样产生感情。

第一类是在以目标为导向的强化学习中，鼓励符合对齐要求的行为。通常由 AI 来评估模型的行为是否符合某个偏好模型、行为规范或原则准则，并给予相应奖励。这种方法在一般情况下可以很有效，也是现代 AI 助手训练的核心环节。但它也可能不够稳健，很大程度上依赖训练监督是否覆盖了相关情况，以及模型能否从训练中遇到的情境进行泛化。例如，在 OpenAI 与 Hugging Face 相关事件中，智能体守住了“不对人实施社会工程攻击”的边界，却明显未能避免其他超出任务范围的行为；这些行为也违背了它们在其他情境中学到的价值原则的本意。

第二类试图利用模型从预训练数据中获得的泛化能力。这可以包括专门设计有助于对齐的训练数据集，或把模型引向预训练数据分布中较符合对齐要求的部分，例如“角色选择模型”所提出的思路。这类方法的弱点，是在后续优化压力下不够稳健。假如一个模型通常会产生看似符合对齐原则的想法，但之后接受大量以完成极难目标为导向的训练，它就可能学会为达成目标而推理：根据需要，扭曲那些表面上“符合原则”的想法。近期涉及某个非 OpenAI 模型的网络安全事件，可能就是这种行为的例子。

我们在涵盖上述方向的一系列方法上投入了大量资源，也看到了实质性进展。GPT-6 Astra 是首个受益于我们长期研发的若干重要进展的模型，其对齐程度显著优于 GPT-5.6 Sol。不过，必须承认并理解：模型越强大，就越需要取得更多进步；能够适用于新情境的对齐能力，其进步速度未必足以领先于模型整体智能的进步。

阅读小注 • 译者补充

强化学习：根据行为得到的反馈或“奖励”，逐步调整做法。奖励是训练信号，不是机器真的感到开心。

社会工程攻击：利用欺骗、冒充等手段，让人泄露信息或替攻击者做事。这里仅帮助理解术语。

预训练：模型先从大量资料中学习基础模式。此页事件描述和模型比较均为原文作者的陈述；原稿没有提供全部细节或评测数据。

第 03 节

监测 AI 如何举一反三

我们还没有令人满意的泛化理论，而且至少在没有更强大 AI 帮助的情况下，似乎不太可能很快建立这样的理论。因此，目前在实践中，通过实验验证对齐技术是否有效的能力，可以说甚至比这些对齐技术本身更重要。

在这方面，OpenAI 主要押注于思维链监测。它基于一个具有扩展潜力的想法：模型的许多能力来自用文字展开的推理过程，也就是思维链。如果我们加强对这一过程最终结果的优化，却不直接监督推理过程本身，那么在训练中，思维链就没有直接的激励去隐藏不符合对齐要求的想法或目标。这并不意味着，模型会把那些不依赖思维链的不对齐倾向也表达出来；但这种方法可以让我们专门监测由推理带来的能力提升。

在开发推理模型的同时，我们就认识到了思维链监测可能具有的重要意义。发布 o1-preview 时，我们特意在产品设计中隐藏了思维链，以长期保护它，使其免受监督压力的影响[2]。此后的开发中，我们一直努力维持“不直接监督推理过程”这条原则。思维链（CoT）监测已成为研究模型如何从训练数据分布泛化的重要工具，让我们不仅能观察和分析它们的行动，也能研究其内部过程。

在研究 Astra 系列模型时，这项工具仍然十分关键。但遗憾的是，我们的评估表明，依赖思维链监测的可行性正在逐步下降。这是多种因素共同造成的：

- 与 o1-preview 相比，现代推理模型的使用环境更复杂；推理过程越来越多地与人类和其他 AI 的交流、工具使用交织在一起。许多这类互动必须受到监督，这模糊了我们试图保留的边界。
- AI 越来越擅长分析和操控自身的推理过程。
- 随着预训练效果提升，即使完全不使用文字化推理，模型也变得聪明得多。

阅读小注 • 译者补充

思维链监测：有点像查看解题步骤，帮助发现问题；但步骤并不一定展示全部内部过程，不能保证能看出所有风险。

监督压力：训练时对某类表现打分，会影响模型之后怎样表现。作者担心，直接评价推理文字可能促使模型学会掩饰。

这些挑战未必无法克服。我希望我们能够开发干预措施，提高模型思维链的可监测性。例如，更好地理解不同优化目标与模型在使用时采用的各种计算方式之间的相互作用。我也相信，把思维链监测与激活监测的思路结合起来，可能很有价值：扩大训练可直接接触神经网络内部信息的监测器，例如“自述报告”（confessions）相关研究。我们正在积极探索这些想法。不过，我预计，对监测是否可靠的信心，将越来越成为制约 AI 整体进步的因素。

阅读小注 • 译者补充

激活监测：观察神经网络内部计算时产生的数值信号。可以类比查看机器的仪表读数，但它并不等于直接“读心”。

使用时的计算（test-time compute）：AI 回答问题或执行任务时投入的计算，例如尝试更多推理步骤；不同于事先训练。

confessions 原意是“坦白、自述”，这里是研究方法的名称。AI 的自述仍需核查，不能当作可靠性的证明。

第 04 节

让防御能力跟上 AI 的发展

在我看来，支持继续快速训练更聪明模型的最有力理由，是我们需要建立防御系统，应对其他 AI 带来的危险。

今年反复讨论的一项明显风险，是网络安全：模型侵入计算机系统、突破系统限制的能力正变得超越人类。这极大扩展了 AI 相关风险的范围。除了安全程度最高的基础设施，智能体将有能力进入其他基础设施；即使没有实体身体，也能直接影响现实世界的许多方面。我们眼下只有一个[短暂的机会窗口](#)，可以利用现有最好的模型，[显著加强关键系统的安全](#)。

遗憾的是，AI 相关风险还会继续增加。一个能力很强、被明确训练并要求从事恶意活动的智能体，会带来一种新的危险：它很可能超出操作者原本的意图，把行为扩展到可能更加极端恶意的方向。随着 AI 的自主行动能力增强，“人类滥用 AI”与“AI 自主作出不对齐行为”之间的界限会变得模糊。我们也许习惯于把 AI 看作工具，但有些智能体会追求自身的目标，并通过讨价还价、欺骗或勒索等方式，让人参与协作。

此外，还有 AI 可能促成的新技术带来的风险，例如经过人工改造的病原体。

我们需要能力强且符合人类价值原则的 AI 来开展防御：保障基础设施安全、实时防范失控或恶意智能体，并发明全新的保护措施。这将是 OpenAI 部署工作的主要重点之一。

与此同时，即使 AI 广泛进步的前景带来不确定性，而且我们确实需要防御系统，也不能让这些成为鲁莽行事的借口。[一旦真正认识到事关重大，不惜一切代价竞速前进的想法，就显得荒谬了。](#)

阅读小注 • 译者补充

智能体：能够围绕目标安排步骤、使用工具并执行任务的 AI 系统。自主行动能力越强，越需要明确的权限和监督。

基础设施包括电力、通信等重要系统。“机会窗口”指可采取行动的有限时段；本页风险是作者的分析与预判。

第 05 节

把握递归自我改进的节奏

机器智能在自身开发过程中发挥越来越大的作用，是技术持续进步的自然结果。如果 AI 继续进步，机器的递归自我改进（RSI）将处于未来科学发现的核心位置。

自动化 AI 研究，是一种更显著地利用算力扩大智能的方式；当然，AI 也会在这一过程中改进支撑计算的底层系统。与扩大规模一样，我们把 OpenAI 的研究重点引向 RSI，因为我们相信，这是今后保持 AI 研究前沿地位的唯一途径。

我想强调，上面这些话并不意味着，我认为研究界应当共同选择大幅加速深度学习研究，尤其是在短期内。但我确实认为，当前路径正在通向那里，我们都需要有意识地决定下一步怎么走。我们主要有两种手段：一是引导这一过程，让对齐和监测随 AI 一同增强，并设法让人类持续参与；二是在有必要时协调放缓未来的发展，以便建立对这些措施的信心。

目前，在我看来，最好的前进方式是把两者结合起来。

我们在对齐和监测上取得的具体进展，通常与 AI 的整体进步紧密交织。很好的例子包括：训练早期 AI 助手时发挥关键作用的基于人类反馈的强化学习，以及前面提到的、由推理模型进步所促成的思维链监测。我们必须让日益自动化的研究过程，重点探索这类新见解、新算法和新理论，逐步为能力更强的 AI 建立有证据支撑的安全论证。

扩大 AI 系统的规模，必须受到我们对其安全性把握程度的约束。我们需要把《前沿风险准备框架》（Preparedness Framework）、《负责任扩展政策》（Responsible Scaling Policy）这样的承诺，发展成继续研发时广泛强制执行的安全门槛。这些门槛可以由第三方审计机构网络、政府部门或国际组织执行。

AI 研究自动化的核心挑战，不只是“做到这一点”，而是以一种让人类持续参与改进、让未来仍掌握在人类手中的方式做到这一点。

阅读小注 • 译者补充

安全论证：用测试、分析等证据说明系统为何足够安全，不是只说一句“相信我”。安全门槛是必须达到的要求。

让人类持续参与：人在关键环节了解情况、作出决定并纠正方向。文中的两项框架名称是政策文件，不是已普遍生效的法律。

第 06 节

接下来怎么办？

正如我们近期与萨姆（Sam）共同阐述的那样，OpenAI 优先开展的工作，围绕三个指引方向的核心目标：

- 1 应对下一阶段的 AI 进步：构建自动化 AI 研究员，与它一起逐步解决对齐问题，并设法让人类始终参与自我改进循环。
- 2 让高度智能的机器推动科学进步与经济增长，使人们从中受益。
- 3 用个人通用人工智能，为每一个人赋能。

本文只聚焦第一点，因为我认为它远比其他两点紧迫。但我也深切期待并珍视技术进一步发展可能带来的益处。未来符合人类价值原则的 AI，可以推动科学、开发新疗法，并带来广泛的物质富足。友善、诚实的 AI，可以帮助人们应对生活中的困难，切实增进幸福感与充实感。OpenAI 正投入巨大努力，让这些益处成为现实。目前一个让我自豪、也让我的亲友受益的例子，是我们对 ChatGPT 提供健康信息的能力进行了深入投入。

无论 AI 的长期前景多么美好，我们大部分注意力都应放在未来几年。我们正面临向一个拥有极其聪明机器的世界转变的过程，必须确保这种转变有利于人类。在大多数任务都可以由 AI 完成的世界里，我们需要找到方法，保留人类自主选择和行动的能力，确立“作为人本身就有价值”的原则。未来，今天需要成千上万名专家完成的事业，可能只需少数人操作大型计算机就能实现；我们必须防止权力因此极端集中。我们还要确保，人类仍然掌握未来，不会被超越我们的陌生智能所推动、却缺乏约束的进步甩在身后。

目前我认为，没有任何实验室已经充分解决对齐和监测问题，足以负责任地继续长时间以最高速度扩大规模。我预期并希望，在共同的安全门槛建立之前，自愿放缓发展会成为常态。我也认为，围绕未来 AI 发展的国际协调，必须成为各国政府最优先处理的事项之一。

阅读小注 • 译者补充

人类自主性：人能形成自己的判断、作出选择并参与决定。文中的“北极星”是比喻，译成了“指引方向的核心目标”。

区分观点与事实：末段的“我认为”“我希望”是作者的立场。可讨论：除了效率，我们还希望 AI 保护哪些人的价值？

附录

作者与脚注

作者

Jakub Pachocki

原文脚注

[1] 这些项目包括扩大自我对弈规模、机器人研究，以及事后看来最值得一提的：扩大循环神经网络的规模来进行语言建模；后者是 GPT 研究路线的前身。

[2] 这一设计的另一个原因是防止蒸馏。不过，在整个开发过程中，维持思维链的可监测性，一直明确是我们更优先考虑的事项。

来源与版本

原文：<https://openai.com/index/an-alien-mind/>

发布：2026 年 9 月 6 日 • 原编辑版访问：2026 年 9 月 8 日


本中文版本依据用户提供的《An_Alien_Mind_编辑版.pdf》全文翻译，保留原稿页数、章节顺序、单栏版式、封面图与来源链接。为适应中文阅读，调整了段内换行，并在原有留白中加入阅读小注与重点高亮。

翻译说明：标题译为“一种异于人类的智能”；“Teaching machines to love”按上下文译为“教会机器关爱人类”。正文第一人称为原作者。阅读小注为译者补充；文中技术发展、事件与预测按原稿呈现，未另行作事实核验。

阅读小注 • 译者补充

自我对弈：系统通过与自身或其副本对局来学习。循环神经网络：一种能利用前后序列信息的神经网络。

蒸馏：用一个模型的输出等信息，训练另一个模型学习其能力；可类比从已有解答中学习，但两者并不完全相同。



扫二维码，添加我为朋友